

# Ri-acquisizione del corpus Dataverse — Runbook del pilota (Fase 1)

Direzione ICT, Università degli Studi di Milano — Progetto Arkive

Luglio 2026

## Indice

|                                                                                         |          |
|-----------------------------------------------------------------------------------------|----------|
| <b>Runbook del pilota — Fase 1</b>                                                      | <b>1</b> |
| 1. Scopo e contesto . . . . .                                                           | 1        |
| 2. Esito della Fase 0 (dati di partenza) . . . . .                                      | 2        |
| 3. Dataset pilota selezionati . . . . .                                                 | 2        |
| 4. Prerequisiti (da verificare PRIMA di iniziare) . . . . .                             | 2        |
| 5. Esecuzione . . . . .                                                                 | 3        |
| 5.1 Camera pulita — DENTRO la Transfer Source Location . . . . .                        | 3        |
| 5.2 Lista DOI del pilota . . . . .                                                      | 4        |
| 5.3 Download . . . . .                                                                  | 4        |
| 6. Gate 1 — Validazione dell’acquisizione . . . . .                                     | 4        |
| 7. Ingest e Gate 2 — Validazione dell’AIP . . . . .                                     | 6        |
| 7.1 Ingest . . . . .                                                                    | 6        |
| 7.2 Gate 2 — controlli sull’AIP . . . . .                                               | 6        |
| 8. I 6 DOI non più raggiungibili . . . . .                                              | 8        |
| 9. Blocchi durante l’ingest — diagnosi e rimedi . . . . .                               | 8        |
| 9.1 Transfer fermo in <code>USER_INPUT</code> . . . . .                                 | 8        |
| 9.2 Nessun job avanza: MCPClient disallineato . . . . .                                 | 8        |
| 9.3 Lo script riaggancia un transfer annullato . . . . .                                | 9        |
| 9.4 Procedura completa di ripartenza pulita . . . . .                                   | 9        |
| 10. Politica di trattamento degli archivi compressi . . . . .                           | 9        |
| 10.1 Il problema . . . . .                                                              | 9        |
| 10.2 Verifica empirica . . . . .                                                        | 10       |
| 10.3 Decisione adottata . . . . .                                                       | 10       |
| 10.4 Applicazione e verifica . . . . .                                                  | 10       |
| 11. Piano dei lotti e calibrazione . . . . .                                            | 11       |
| 11.1 Dati di calibrazione misurati . . . . .                                            | 11       |
| 12. Criteri di GO / NO-GO per il lotto completo . . . . .                               | 11       |
| 13. Registrazione dell’esito . . . . .                                                  | 12       |
| 13.1 Esito del pilota del 22 luglio 2026 . . . . .                                      | 12       |
| 13.2 Esito della calibrazione sul primo lotto reale ( <code>LOTTO_27</code> ) . . . . . | 12       |

## Runbook del pilota — Fase 1

### 1. Scopo e contesto

Il corpus Dataverse è stato acquisito e ingerito in Archivematica **prima** che la pipeline introducesse due comportamenti oggi ritenuti necessari:

1. la **verifica di integrità** dei file scaricati (checksum/dimensione), che impedisce a un download troncato di entrare silenziosamente nel SIP;

2. la **conservazione dell'originale** per i file ingeriti come tabellari (`format=original`), invece della derivata `.tab` generata da Dataverse.

Poiché gli AIP prodotti finora sono **sperimentali** (progetto in fase avanzata ma non ancora in produzione), è stato deciso di **non migrare** i pacchetti esistenti ma di **ri-acquisire l'intero corpus** con la pipeline corretta e ricostruire gli AIP da una baseline pulita. Questo evita di trascinare nella futura produzione catene di `supersede` e record di `deaccession` relativi a materiale di prova, e — cosa più importante — sottopone a verifica di integrità **tutto** il corpus, non solo i dataset con l'anomalia nota.

Questo documento descrive la **Fase 1**: l'esecuzione controllata del ciclo completo su **due dataset pilota**, allo scopo di validare la procedura prima di applicarla ai 702 dataset dello scope. Il prodotto della Fase 1 non è solo “due pacchetti corretti”, ma **la procedura verificata** da ripetere sul lotto.

## 2. Esito della Fase 0 (dati di partenza)

La ricognizione con `verifica_raggiungibilita.py` sui 708 DOI dello scope ha dato:

| Indicatore                                    | Valore          |
|-----------------------------------------------|-----------------|
| DOI ri-acquisibili (OK)                       | <b>672</b>      |
| DOI vuoti (nessun file in nessuna versione)   | 30              |
| DOI <b>non più raggiungibili</b> su Dataverse | <b>6</b>        |
| DOI con file ad accesso ristretto             | 111             |
| Versioni totali da scaricare                  | 1 226           |
| File totali da scaricare                      | 67 730          |
| Volume stimato (originali, tutte le versioni) | <b>62,95 GB</b> |

I 6 DOI non più raggiungibili — QA4BR0, BX8AIN, YF2NZV, WKMYTV, YIAURF, OYDM83 — sono **fuori dallo scope della ri-acquisizione** e vanno trattati a mano: vedi sezione 8.

## 3. Dataset pilota selezionati

I due pilota sono scelti per **esercitare i percorsi nuovi**, non per comodità:

| Pilota   | DOI                          | Versioni | File | Ingeriti | Ristretti | Volume |
|----------|------------------------------|----------|------|----------|-----------|--------|
| <b>A</b> | doi:10.13130/RD_UNIMI/PKZ7FJ | 4        | 10   | 8        | 0         | 4,3 MB |
| <b>B</b> | doi:10.13130/RD_UNIMI/DP08SC | 3        | 26   | 23       | 25        | 1,1 MB |

**Perché A:** quattro versioni e otto file ingeriti su dieci. Valida in un colpo solo la struttura per versione (`objects/<versione>/objects/`), il download `format=original` e l'identificazione dei formati reali, restando piccolo.

**Perché B:** quasi tutti i file sono **contemporaneamente ristretti e ingeriti** (25 ristretti, 23 ingeriti su 26). È l'intersezione più rischiosa dell'intero corpus: richiede che `format=original` funzioni **su file ad accesso ristretto con API key**. Se in quella combinazione mancasse un permesso, il pacchetto risulterebbe silenziosamente incompleto su una parte significativa dei 111 DOI ristretti.

## 4. Prerequisiti (da verificare PRIMA di iniziare)

Nessuno di questi punti è formale: ognuno corrisponde a un incidente già occorso.

**4.1 Sincronizzazione Dropbox disattivata sulla cartella di lavoro.** Per il pilota è sufficiente la sospensione della sincronizzazione. Per il lotto completo va valutata la Selective Sync o lo spostamento della cartella fuori da Dropbox (vedi sezione 9).

**4.2 Mount drvfs con opzione metadata.** Senza di essa `utime()` fallisce e lo store dell'AIP termina con errore `rsync` codice 23 anche quando il trasferimento dei file è riuscito. Verifica:

```
mount | grep drvfs
# atteso: ... type drvfs (rw,noatime,...,metadata,uid=...,gid=...,umask=022)
cat /etc/wsl.conf
```

**4.3 Spazio disponibile.** Per il pilota bastano pochi MB, ma è il momento giusto per misurare l'headroom in vista del lotto (63 GB di download più lavorazione Archivematica e AIP risultanti):

```
df -h /mnt/e
```

**4.4 File .env completo,** con `DATAVERSE_API_KEY` valorizzata: **indispensabile** per il Pilota B (file ristretti). Verifica rapida senza stampare la chiave:

```
cd tools/dataverse-archivematica
grep -c DATAVERSE_API_KEY .env # atteso: 1
```

**4.5 Utente di esecuzione.** Gli script della pipeline **non vanno mai eseguiti come utente archivematica**. Verifica con `whoami`.

**4.6 Versione degli script.** Il pilota ha senso solo con la pipeline aggiornata:

```
git log --oneline -1
grep -c "_is_ingested_tabular" scarica_dataverse.py # atteso: >= 2
grep -c "doi_path.resolve()" archivematica_ingest.py # atteso: 1
```

**4.7 Processing configuration corretta — condizione critica.** Due scelte di `dataverse_001` determinano la qualità archivistica degli AIP:

| Decisione                                              | Valore richiesto                  |
|--------------------------------------------------------|-----------------------------------|
| Perform file format identification ( <b>Transfer</b> ) | <b>Yes</b>                        |
| Perform file format identification (Ingest)            | <i>No, use existing data</i>      |
| <b>Normalize</b>                                       | <b>Normalize for preservation</b> |
| Approve normalization                                  | Yes                               |

Senza identificazione in fase di transfer, il METS riporta Unknown per **tutti** gli oggetti: niente PUID, niente pianificazione della conservazione, e la normalizzazione non può funzionare (il FPR sceglie le regole in base al formato riconosciuto). L'impostazione "*No, use existing data*" in ingest è corretta solo se l'identificazione in transfer è attiva, altrimenti non esistono dati da riusare.

Il file **non va modificato a mano**: gli UUID delle catene variano tra versioni di Archivematica. Si genera dal Dashboard (*Administration -> Processing configuration -> dataverse\_001 -> Edit -> Save -> Download*) e si copia nella posizione della copia locale versionata. Verifica:

```
CFG=~/.arkive/config/dataverse_001ProcessingMCP.xml
grep -A2 "f09847c2-ee51-429a-9478-a860477f6b8d" $CFG # identificazione: NON "Skip"
grep -A2 "cb8e5706-e73f-472f-ad9b-d1236af8095f" $CFG # normalizzazione
grep -A2 "7509e7dc-1e1b-4dce-8d21-e130515fce73" $CFG # normalizzazione (2° punto)
```

## 5. Esecuzione

### 5.1 Camera pulita — DENTRO la Transfer Source Location

La ri-acquisizione **non** si sovrappone a cartelle esistenti: la pipeline salva ora i nomi originali (`.csv`, `.dta`), quindi su una cartella popolata in passato scaricherebbe gli originali **accanto** ai vecchi `.tab`, lasciando entrambi.

La cartella di lavoro deve inoltre trovarsi **fisicamente dentro il percorso della Transfer Source Location** dello Storage Service. Motivo: `archivematica_ingest.py` avvia il transfer passando `base64(<location_uuid>:<path_a`

e lo Storage Service accetta solo percorsi interni alla location. Un pacchetto fuori da lì non verrebbe visto da Archivematica.

Allo stesso tempo la cartella deve essere una **sottocartella dedicata**, non la radice della Transfer Source: se si omette `--source`, lo script raccoglie *tutti* i pacchetti DOI presenti nella location, compresi quelli della vecchia acquisizione, che il pilota non deve toccare.

```
# 1) ricavare il percorso della Transfer Source Location (o usare quello noto)
TS_PATH=/percorso/della/transfer_source      # adattare

# 2) creare la sottocartella dedicata al pilota, vuota
mkdir -p "$TS_PATH/PILOTA"
ls -A "$TS_PATH/PILOTA"                      # deve essere vuota
```

Se il download è già stato eseguito altrove, spostare i pacchetti (non copiarli, per non lasciare duplicati):

```
mv PILOTA/doi_* "$TS_PATH/PILOTA"/
```

## 5.2 Lista DOI del pilota

```
cat > dois_pilota.txt << 'EOF'
doi:10.13130/RD_UNIMI/PKZ7FJ
doi:10.13130/RD_UNIMI/DP08SC
EOF
```

## 5.3 Download

```
python3 scarica_dataverse.py --dois dois_pilota.txt --output "$TS_PATH/PILOTA" --dcat \
2>&1 | tee logs/pilota_download.log
```

`--dcat` è necessario: il pilota deve validare anche che la `dcat:distribution` descriva l'originale.

## 6. Gate 1 — Validazione dell'acquisizione

Non procedere all'ingest se anche uno solo di questi controlli fallisce.

**6.1 Nessun errore di download.** Nel `riepilogo_download.json` entrambi i DOI devono risultare ok, mai partial:

```
python3 -c "
import json,os; TS=os.environ['TS_PATH']
d=json.load(open(TS+'/PILOTA/riepilogo_download.json'))
print(json.dumps(d, indent=2)[:800])
"

grep -c "ERRORE\\|[RISCARICO]" logs/pilota_download.log    # atteso: 0
```

**6.2 Nessun fallback alla derivata.** Se compare `[FALLBACK]`, per quel file `format=original` non ha risposto e nel pacchetto è finita la `.tab`:

```
grep "\[FALLBACK\]" logs/pilota_download.log    # atteso: nessun risultato
```

Controllo di contabilità speculare, che conferma il caso positivo:

```
grep -c "Scarico:" logs/pilota_download.log    # atteso: 36 (10 + 26)
grep -c "originale di" logs/pilota_download.log    # atteso: 31 (8 + 23)
```

Il primo è il totale dei file scaricati, il secondo quelli scaricati **come originale** al posto della derivata (etichetta `nome.csv` (originale di `nome.tab`)). La differenza ( $36 - 31 = 5$ ) deve corrispondere ai file **non** ingeriti, cioè privi di un originale distinto. Se la contabilità non chiude, qualche file ingerito non è stato trattato come tale e va indagato prima di procedere.

**6.3 Sono stati conservati gli ORIGINALI, non i .tab.** È il controllo centrale del Livello 2:

```
find "$TS_PATH/PILOTA" -name "*.tab" | head          # atteso: NESSUN risultato
find "$TS_PATH/PILOTA" -path "*/objects/*" -type f -not -path "*/metadata/*" | head -20
```

**I nomi vanno preservati esattamente come depositati.** Nell'elenco è normale — e corretto — trovare nomi con spazi (IVD\_NMBU shipment 2\_cytotoxicity\_NRU.xlsx) o con estensioni anomale ripetute (...\_ANPEP.xlsx.xlsx). La pipeline usa `originalFileName` così com'è: quei nomi sono letteralmente quelli con cui il ricercatore ha depositato i file. Conservarli invariati, refusi compresi, è il comportamento corretto ai fini dell'autenticità dell'oggetto archiviato; una normalizzazione silenziosa produrrebbe oggetti diversi dagli originali.

**6.4 Struttura per versione completa.** Il Pilota A deve avere 4 versioni, il Pilota B 3:

```
ls -d "$TS_PATH"/PILOTA/*PKZ7FJ*/objects/*/      # atteso: 4 directory
ls -d "$TS_PATH"/PILOTA/*DP08SC*/objects/*/      # atteso: 3 directory
ls "$TS_PATH"/PILOTA/*DP08SC*/objects/*/metadata/
```

**Asimmetria attesa nei metadati di versione:** `dataverse.json`, `dcat.json` e `metadata.csv` sono presenti in **ogni** versione perché generati localmente dalla pipeline; `schema.json` compare **solo nell'ultima versione**, perché è scaricato dall'exporter Schema.org di Dataverse, che lavora a livello di dataset e non espone le versioni storiche. La sua assenza nelle versioni precedenti **non è un errore di export**. Da verificare invece se mancasse in modo irregolare (per esempio assente anche nell'ultima versione, o presente a intermittenza).

**6.5 I file ristretti sono stati scaricati (Pilota B).** Contro il rischio del pacchetto silenziosamente incompleto: il numero di file di dati presenti su disco deve corrispondere a quello atteso dal report di Fase 0.

```
find "$TS_PATH"/PILOTA/*DP08SC* -path "*/objects/*" -type f \
-not -path "*/metadata/*" | wc -l          # atteso: 26
```

L'esclusione di `*/metadata/*` è necessaria: nella struttura `objects/<versione>/metadata/` la parola `objects` compare comunque nel percorso, quindi senza il filtro verrebbero conteggiati anche `dcat.json`, `metadata.csv`, `dataverse.json` e `schema.json`, falsando il totale.

**6.6 Il DCAT descrive l'originale.**

```
python3 -c "
import json,glob,os
TS=os.environ['TS_PATH']
for p in sorted(glob.glob(TS+'*/PILOTA*/objects/*/metadata/dcat.json'))[:2]:
    d=json.load(open(p)); dd=d.get('dcat:distribution')
    dd=dd if isinstance(dd,list) else [dd]
    print(p)
    for x in dd[:3]:
        print(' ', x.get('dct:title'), '|', x.get('dcat:mediaType'), '|',
              x.get('dcat:accessURL',{}).get('@id','')[-30:])
"
```

Atteso: titoli con estensione originale (`.csv`, `.xlsx`, `.dta`), `mediaType` dell'originale (**non** `text/tab-separated-values`) e `accessURL` che termina con `?format=original`.

**Attenzione** — è normale che alcune `accessURL` NON abbiano `?format=original`. La pipeline decide file per file: i file **non ingeriti** da Dataverse (privi dei campi `original*`) non hanno una rappresentazione originale distinta, quindi il loro `accessURL` è quello semplice. Aggiungere `?format=original` significherebbe descrivere una rappresentazione inesistente. Un `.xlsx` può benissimo non essere stato ingerito (fogli multipli, dimensione, ingest non riuscito): non è un errore.

Verifica di contabilità sull'intero pilota, che chiude il cerchio con il log:

```
python3 - << 'EOF'
import json, glob, os
```

```

TS=os.environ['TS_PATH']
tot=orig=plain=0
for p in sorted(glob.glob(TS+'//PILOTA/*/objects/*/metadata/dcat.json')):
    d=json.load(open(p)); dd=d.get('dcat:distribution') or []
    dd=dd if isinstance(dd,list) else [dd]
    for x in dd:
        tot+=1
        u=x.get('dcat:accessURL',{}).get('@id','')
        if u.endswith('?format=original'): orig+=1
        else: plain+=1
        if 'tab-separated' in (x.get('dcat:mediaType') or ''):
            print('!! ANOMALIA (mediaType .tab):', p, x.get('dct:title'))
print(f"distribution totali: {tot} con format=original: {orig} senza: {plain}")
EOF

```

Atteso: **36 totali, 31 con format=original, 5 senza** — gli stessi numeri dei `grep` del punto 6.2. Nessuna riga di anomalia. In caso di dubbio su un singolo file, la conferma si legge in `dataverse.json`: se `originalFileName` e `originalFileFormat` sono `None`, il file non è ingerito e l'URL semplice è corretto.

**6.7 metadata.csv coerente.** La colonna `filename` è costruita leggendo il disco, quindi deve elencare i nomi originali:

```
head -3 "$TS_PATH"/PILOTA/*PKZ7FJ*/metadata/metadata.csv
```

## 7. Ingest e Gate 2 — Validazione dell'AIP

### 7.1 Ingest

```
python3 archivematica_ingest.py --source "$TS_PATH/PILOTA" --auto-approve \
--state-file stato_pilota.json 2>&1 | tee logs/pilota_ingest.log
```

Due accorgimenti, entrambi necessari:

- **--source esplicito.** Omettendolo, lo script userebbe la radice della Transfer Source Location e raccoglierebbe *tutti* i pacchetti DOI presenti, inclusi quelli della vecchia acquisizione: il pilota ingerirebbe molto più del previsto. Puntando alla sottocartella si lavora solo sui due dataset.
- **File di stato separato** (`stato_pilota.json`), per non mescolare il pilota con lo storico di produzione in `stato_archivematica.json`.

Prima di lanciare, verificare che nella sottocartella ci siano esattamente i due pacchetti attesi:

```
ls -d "$TS_PATH/PILOTA"/doi_* # atteso: 2 directory
```

### 7.2 Gate 2 — controlli sull'AIP

**7.2.1 AIP presente e memorizzato.** Annotare gli UUID e verificare lo stato:

```
python3 - << 'EOF'
import os, requests, urllib3
urllib3.disable_warnings()
for l in open('.env'):
    l=l.strip()
    if l and not l.startswith('#') and '=' in l:
        k,_,v=l.partition('='); os.environ.setdefault(k.strip(), v.strip().strip('"\''))
SS=os.environ.get('SS_URL','http://localhost:8000')
H={'Authorization': f"ApiKey {os.environ['SS_USER']}:{os.environ['SS_API_KEY']}"}
for nome,uuid in [('DP08SC','<AIP-UUID>'), ('PKZ7FJ','<AIP-UUID>')]:
    d=requests.get(f"{SS}/api/v2/file/{uuid}/",headers=H,verify=False,timeout=60).json()
    print(f"{nome}: status={d.get('status')} size={d.get('size')}")
EOF

```

```

    print(f"    {d.get('current_full_path')}")
EOF

```

Atteso: `status=UPLOADED`. Le dimensioni devono essere coerenti con il volume degli originali stimato in Fase 0.

**7.2.2 Formati, eventi e agenti — il controllo decisivo.** Legge il METS dall'AIP compresso senza estrarlo:

```

python3 - << 'EOF'
import tarfile, glob, re
from collections import Counter
import xml.etree.ElementTree as ET
for uuid, nome in [('<primi8>', 'DP08SC'), ('<primi8>', 'PKZ7FJ')]:
    aip = glob.glob(f"/mnt/e/ARKIVE/AIPsStore/{uuid[:4]}/**/*{uuid}*.tar.gz", recursive=True)
    with tarfile.open(aip[0]) as t:
        mets=[m for m in t.getnames() if re.search(r'/data/METS\..*\.xml$', m)]
        xml=t.extractfile(mets[0]).read()
        root=ET.fromstring(xml); tag=lambda e: e.tag.split(' ')[-1]
        print(f"n=== {nome}")
        for f,n in Counter(e.text for e in root.iter() if tag(e)=='formatName').most_common():
            print(f"    {n:4d} {f}")
        for e,n in Counter(x.text for x in root.iter() if tag(x)=='eventType').most_common():
            print(f"    [ev] {n:4d} {e}")
EOF

```

Attesi e criteri di lettura:

- i formati devono essere **identificati**: Microsoft Excel, CSV, Plain Text, JSON Data Interchange Format... e **nessun Unknown**;
- **nessun Tab-Separated Values** tra gli oggetti: se comparisse, nell'AIP è finita una derivata invece dell'originale;
- deve esserci un evento **format identification** per ogni oggetto;
- gli eventi **normalization** compaiono **solo per i formati con una regola FPR** (tipicamente PDF, immagini, audio, video). La loro assenza sugli `.xlsx` non è un guasto: il FPR considera quei formati già adeguati alla conservazione;
- l'agente e la versione dello strumento di identificazione si leggono nell'`eventDetail` (es. `program="Siegfried"; version="1.11.2"`).

**7.2.3 Conteggio degli oggetti — attenzione a cosa si conta.** Il numero di file nel METS è **maggiore** di quello dei file di dati, perché i metadati per versione (`objects/vX.Y/metadata/...`) stanno dentro `objects/` e Archivematica li tratta come contenuto. Per DP08SC: 26 file di dati + 10 metadati = 36; per PKZ7FJ: 10 + 13 = 23. Solo la cartella `metadata/` di primo livello è trattata come metadati descrittivi.

**7.2.4 Nomi originali preservati.** Archivematica **sanifica** i nomi con spazi o caratteri problematici sul filesystem e registra ogni modifica con un evento **filename change**. Il nome di deposito resta documentato nel METS in `originalName`. Verifica che gli spazi ci siano ancora:

```

python3 - << 'EOF'
import tarfile, glob, re
import xml.etree.ElementTree as ET
uuid='<primi8>'
aip=glob.glob(f"/mnt/e/ARKIVE/AIPsStore/{uuid[:4]}/**/*{uuid}*.tar.gz", recursive=True)
with tarfile.open(aip[0]) as t:
    mets=[m for m in t.getnames() if re.search(r'/data/METS\..*\.xml$', m)]
    xml=t.extractfile(mets[0]).read()
    root=ET.fromstring(xml); tag=lambda e: e.tag.split(' ')[-1]
    orig=[e.text for e in root.iter() if tag(e)=='originalName' and e.text and not e.text.endswith('/')]]

```

```
print("con spazi nel nome:", sum(1 for o in orig if ' ' in o.split('/')[1]), "su", len(orig))
EOF
```

**7.2.5 Fixity.** Nessun evento PREMIS di *fixity check* fallito.

## 8. I 6 DOI non più raggiungibili

QA4BR0, BX8AIN, YF2NZV, WKMYTV, YIAURF, OYDM83 non esistono più su `dataverse.unimi.it` (verificato via API, browser e curl). Per questi la ri-acquisizione è **impossibile**, quindi:

1. **Prima di qualunque pulizia**, verificare se ne esiste una copia locale (nelle cartelle di download o negli AIP già prodotti) e, in caso affermativo, **metterla al sicuro fuori dall'area di lavoro**: sarebbe l'unico esemplare rimasto.
2. **Segnalare la scomparsa ai responsabili di Data@UNIMI**. Sei dataset pubblicati con DOI assegnato che spariscono da un repository certificato CoreTrustSeal richiedono una spiegazione (deaccession su richiesta dell'autore, DOI di test rimossi, o altro), che va documentata.
3. Non includerli nella lista del lotto.

## 9. Blocchi durante l'ingest — diagnosi e rimedi

Questi casi si sono presentati tutti durante la calibrazione del primo lotto e sono destinati a ripresentarsi su 27 lotti. Vanno riconosciuti in fretta perché, a colpo d'occhio, si somigliano molto: lo script attende, il transfer risulta `PROCESSING`, e apparentemente “non succede nulla”.

### 9.1 Transfer fermo in `USER_INPUT`

Archivematica ha incontrato una decisione **non coperta** dalla `processingMCP.xml` e attende una risposta. L'opzione `--auto-approve` gestisce solo l'approvazione iniziale del transfer, non le scelte successive.

Il caso riscontrato: un dataset composto da un unico archivio compresso ha fatto comparire la domanda “**Extract packages?**”, assente dalla configurazione. La soluzione non è rispondere a mano — su 672 pacchetti si ripresenterebbe decine di volte — ma **aggiungere la scelta alla processing configuration** e rilanciare.

Impostazione adottata: **Extract packages = Yes, Delete packages after extraction = No**. In questo modo l'AIP contiene sia l'archivio originale come depositato (autenticità) sia il contenuto estratto, identificato, verificato e normalizzato (conservazione effettiva). Conservare un archivio non estratto significherebbe custodire un oggetto opaco: nessuna identificazione dei formati interni, nessun monitoraggio dell'obsolescenza, nessuna normalizzazione possibile.

**Il `processingMCP.xml` viene letto all'AVVIO del transfer.** Aggiornare la configurazione mentre un transfer è in corso non ha alcun effetto su quel transfer: va annullato e riavviato. Verificare inoltre che il file **dentro il pacchetto** sia quello nuovo (lo script lo ricopia a ogni esecuzione, ma un transfer già avviato usa la copia letta in partenza).

### 9.2 Nessun job avanza: `MCPClient` disallineato

Sintomo: `[approve]` Nessun transfer in attesa trovato ripetuto, poi `[transfer]` stato: `PROCESSING` all'infinito. In Dashboard il transfer non progredisce.

Causa: dopo aver **fermato e riavviato MCPServer** (operazione necessaria per pulire le watched directory), `MCPClient` resta agganciato alla sessione Gearman precedente e smette di prelevare i job. Il server li accoda, nessuno li esegue.

L'insidia è che tutti i servizi risultano `active`: il segnale vero è il **disallineamento degli orari di avvio** e l'assenza di righe recenti `*** RUNNING TASK: ... ***` nel log del client.

```
systemctl status archivematica-mcp-server archivematica-mcp-client gearman-job-server
sudo journalctl -u archivematica-mcp-client -n 30 --no-pager
```



**Regola operativa:** dopo ogni riavvio di MCPServer, riavviare anche MCPClient.

```
sudo systemctl start archivematica-mcp-server
sudo systemctl restart archivematica-mcp-client
```

### 9.3 Lo script riaggancia un transfer annullato

Sintomo: nel log compare Transfer UUID (ripresa): <uuid> seguito da tentativi di approvazione che non trovano mai nulla. Lo script non sta avviando un transfer nuovo: sta cercando di riprendere quello registrato nel file di stato, che nel frattempo è stato annullato dalla Dashboard e quindi non comparirà mai tra i transfer in attesa.

È il rovescio del meccanismo di ripresa (find\_transfer\_uuid\_by\_name), utile dopo un timeout di rete ma dannoso quando il transfer è stato eliminato di proposito.

**Rimedio:** annullando un transfer dalla Dashboard, rimuovere anche la voce corrispondente dal file di stato, così il DOI riparte da zero.

```
cp stato_riacquisizione.json stato_riacquisizione.json.bak
python3 - << 'EOF'
import json
p='stato_riacquisizione.json'; d=json.load(open(p))
k='doi_10.13130_RD_UNIMI_XXXXXX'      # adattare
if k in d:
    print("rimuovo:", d.pop(k)); json.dump(d, open(p,'w'), indent=2, ensure_ascii=False)
print("voci rimaste:", len(d))
EOF
```

Al rilancio il log deve mostrare Avvio transfer '...' con un UUID **nuovo**, non più Transfer UUID (ripresa).

### 9.4 Procedura completa di ripartenza pulita

Quando un pacchetto va rifatto da zero, l'ordine conta:

1. interrompere lo script (Ctrl-C: lo stato è già su disco);
2. annullare il transfer dalla Dashboard;
3. `sudo systemctl stop archivematica-mcp-server`;
4. rimuovere le copie residue del pacchetto dalle watched directory (`sudo find /var/archivematica/sharedDirectory/watched -maxdepth 3 -name "*<DOI>*"`);
5. `sudo systemctl start archivematica-mcp-server` e `sudo systemctl restart archivematica-mcp-client`;
6. rimuovere la voce del DOI dal file di stato (9.3);
7. verificare che il `processingMCP.xml` nel pacchetto sia quello aggiornato;
8. rilanciare lo stesso comando di ingest.

## 10. Politica di trattamento degli archivi compressi

Questa sezione documenta una **decisione di politica di conservazione**, presa durante il pilota sulla base di verifiche empiriche. Va conservata come tale: non è un dettaglio di configurazione, ma una scelta che determina la forma degli oggetti conservati e che va poter essere motivata in sede di audit.

### 10.1 Il problema

Con `Extract packages = Yes` Archivematica estrae gli archivi e tratta ogni file interno come oggetto autonomo. La scelta è stata attivata perché conservare un archivio non estratto significa custodire un oggetto **opaco**: nessuna identificazione dei formati interni, nessun monitoraggio dell'obsolescenza, nessuna normalizzazione possibile.

Il censimento dello scope (`censisci_archivi.py`) ha però mostrato che i file riconosciuti come "archivio" appartengono a **due categorie molto diverse**:

| Categoria                     | Esempi                                                      | L'estrazione è...                                             |
|-------------------------------|-------------------------------------------------------------|---------------------------------------------------------------|
| <b>Contenitori veri</b>       | FIBRE.zip, Output.zip,<br>MARBLE.rar, qcr_instances.tgz     | <b>utile:</b> dentro c'è una gerarchia di file identificabili |
| <b>File singoli compressi</b> | *.rds (serializzazioni R), *.Rdata,<br>*.fastq.gz, *.sql.gz | <b>dannosa:</b> produce un blob non utilizzabile              |

Un `.rds` non è un contenitore: è il formato nativo di R, compresso con gzip. Dataverse ne dichiara il `contentType` come `application/gzip` e Siegfried lo identifica come **GZip (PUID x-fmt/266)**, quindi la regola di estrazione del FPR si attiva.

## 10.2 Verifica empirica

Test su doi:10.13130/RD\_UNIMI/HADWPV (3 file, di cui un `.rds` da 814 KB), METS dell'AIP risultante:

- **1 evento unpacking** → il `.rds` è stato effettivamente estratto;
- tra i formati compare **1 Unknown** → il contenuto estratto è la serializzazione R grezza, che nessun registro di formati riconosce;
- oggetti totali 11 anziché 10.

L'estrazione produce quindi **zero guadagno di conservazione**: da un `.rds` valido esce un blob inservibile senza il wrapper. L'originale resta (grazie a `Delete packages after extraction = No`), ma accanto vi è un duplicato inutile.

**Impatto sullo scope:** i dataset a base `.rds` sommano circa **11 500 file** (NZRX1C 6 615, PLHGBP 1 620, UGSD3F 1 620, UZ25HQ 1 080, V0TP76 285, 1MZNS 180 e altri). L'estrazione ne genererebbe circa **23 000** anziché 11 500, con il relativo tempo di processing e nessun beneficio. Sui `.fastq.gz` si aggiungerebbe una forte crescita di spazio, dato che il formato compresso è la forma standard di distribuzione dei dati di sequenziamento.

## 10.3 Decisione adottata

**Disabilitare la regola di estrazione per il formato GZip** (FPR → *Preservation Planning*, regola UUID 3a19a758-481f-4fdc-9bb4-4052eb150d62, PUID x-fmt/266), mantenendo attive quelle per ZIP, 7z, TAR e RAR.

Motivazione da verbale: *l'estrazione dei file GZip a file singolo produce oggetti non utilizzabili e non identificabili, senza alcun guadagno di conservazione, mentre l'oggetto autentico da preservare è il file compresso stesso. I casi in cui la regola danneggia (migliaia di `.rds` e `.fastq.gz`) sono largamente prevalenti su quelli in cui gioverebbe (una decina di dataset con veri archivi `.tar.gz`).*

**Contropartita accettata:** i veri archivi `.tar.gz/.tgz` non vengono più estratti e restano conservati come bitstream. Riguarda T99WYI, EIMQRQ, 3QA23K, IHTWC0, WHRHCT, BFQ87D, WCZXRK. Per questi si potrà definire in seguito un trattamento dedicato.

**Da verificare prima di applicare:** come Siegfried identifica un `.tar.gz`. Se lo riconosce come TAR annidato in GZip, disabilitando la regola GZip si perde l'estrazione anche su quei dataset; se esiste una regola TAR autonoma (PUID x-fmt/265), continueranno a funzionare e la contropartita si annulla.

## 10.4 Applicazione e verifica

1. In FPR: Replace sulla regola → Enabled: No. **Disabilitare, non eliminare:** la regola resta tracciata e la scelta è reversibile.
2. La modifica vale solo per i transfer **avviati dopo:** quelli in corso usano le regole lette in partenza.
3. Verifica sullo stesso dataset di test: rimuovere la voce dal file di stato, rilanciare l'ingest e controllare che nel METS **non compaia più** l'evento `unpacking` e che il conteggio degli oggetti scenda da 11 a 10.
4. Gli AIP di prova prodotti prima della modifica vanno rifatti insieme al resto del corpus.

## 11. Piano dei lotti e calibrazione

Lo scope si suddivide con `prepara_lotti.py`, che legge il report di Fase 0 e bilancia i lotti su **numero di file** e **volume**, non sul conteggio dei DOI: il corpus è estremamente disomogeneo (da 1 file a quasi 15 000 per dataset) e lotti “da N DOI” avrebbero durate imprevedibili.

```
python3 prepara_lotti.py --max-file 2000 --max-gb 20 --max-doi 200 --scrivi
```

Con queste soglie lo scope dei 672 DOI si ripartisce in **27 lotti** (67 730 file, 62,95 GB). La struttura riflette due popolazioni distinte:

- **lotti 01-20:** dominati dal numero di file, quasi tutti un solo DOI (il maggiore ha 14 888 file, il 22% dei file dell'intero corpus);
- **lotti 21-27:** dominati dal numero di pacchetti (511 DOI per ~2 100 file), dove il costo è quasi tutto overhead per transfer.

**Un solo file di stato per l'intera ri-acquisizione** (`stato_riacquisizione.json`): è ciò che impedisce doppi ingest se un DOI comparisse in due lotti o se un lotto venisse rilanciato.

### 11.1 Dati di calibrazione misurati

Dal primo lotto reale (111 DOI, 118 file, 2 GB — quasi solo overhead):

| Indicatore                 | Valore                                            |
|----------------------------|---------------------------------------------------|
| Pacchetti completati       | 110 su 111                                        |
| Tempo totale ingest        | 75,5 min                                          |
| <b>Media per pacchetto</b> | <b>41,6 s</b> (mediana 40 s, min 25 s, max 251 s) |

Il tempo per pacchetto è dominato dall'attesa di approvazione (10 s) e dal polling (intervalli di 15 s), quindi è **indipendente dalla dimensione del pacchetto**. Estrapolando sui 672 pacchetti: circa **7,8 ore di solo overhead**, a cui si somma il lavoro effettivo sui dataset con molti file.

Ne discende che alzare le soglie per lotto **non allunga i tempi totali** (i pacchetti restano 672): riduce solo il numero di cicli manuali. Se le ore di polling diventassero un problema, l'unica leva è ridurre gli intervalli in `archivematica_ingest.py`, valutando però il carico sulla Dashboard.

Resta da misurare il **costo per file** dentro un pacchetto, con un lotto a pacchetto singolo e molti file (es. 1 DOI / ~1 000 file): con i due coefficienti si può stimare ogni riga del piano, incluso il lotto oversize.

## 12. Criteri di GO / NO-GO per il lotto completo

Si procede al lotto dei 702 dataset **solo se**:

- entrambi i Gate del pilota sono superati senza eccezioni;
- in particolare il Pilota B dimostra che i file **ristretti** e **ingeriti** vengono scaricati come originali (nessun [FALLBACK], conteggio file corretto);
- è stata presa una decisione **strutturale** sulla collocazione di `TRANSFER_SOURCE`: 63 GB in 67 730 file dentro una cartella sincronizzata con Dropbox riproporrebbero i lock transitori su larga scala. La sospensione manuale della sincronizzazione non è sufficiente per una lavorazione lunga, perché Dropbox può riprendere dopo un riavvio o un aggiornamento del client;
- lo spazio disponibile copre 63 GB di download più lavorazione e AIP;
- è stato definito il **dimensionamento dei lotti** (per esempio 50–100 DOI per volta) e il punto di ripresa in caso di interruzione. I lotti si organizzano in **sottocartelle della Transfer Source Location** (`LOTTO_01`, `LOTTO_02`...), da indicare con `--source`: è verificato che Archivematica le risolva correttamente. Omettere `--source` farebbe usare la radice della location, con il rischio di rilavorare tutti i pacchetti presenti;

- la **processing configuration** è quella corretta (prerequisito 4.7): un errore qui obbligherebbe a rifare tutti gli AIP del lotto;
- la **politica di trattamento degli archivi** è stata decisa e applicata (sezione 10), e verificata con il test del `.rds`: modificarla a metà lavorazione produrrebbe un corpus disomogeneo, con alcuni AIP contenenti blob estratti e altri no;
- il **censimento degli archivi** (`censisci_archivi.py`) è completo, senza DOI rimasti non analizzati: i dataset che contengono archivi hanno un carico reale molto superiore a quello dichiarato dall'API e vanno collocati nei lotti di conseguenza.

Nota a favore: la ri-acquisizione è ripartibile in sicurezza. Lo skip si basa su dimensione e checksum, quindi rilanciare non lascia file monchi; un download interrotto viene ri-caricato al passaggio successivo.

## 13. Registrazione dell'esito

Al termine del pilota annotare, per ciascun dataset: data di esecuzione, esito dei due Gate, UUID dell'AIP prodotto, anomalie riscontrate e correzioni applicate. Questo verbale è la base documentale della ricostruzione del corpus e va conservato insieme alla documentazione del progetto.

### 13.1 Esito del pilota del 22 luglio 2026

**Gate 1 superato** su entrambi i dataset: 36 file scaricati (10 + 26), di cui 31 come originali (`format=original`) e 5 non ingeriti; nessun `[FALLBACK]`, nessun `.tab` su disco, nessun errore o riscarico. Le 4 versioni di PKZ7FJ e le 3 di DP08SC complete. Le 36 `dcats:distribution` coerenti: 31 con `?format=original`, 5 senza (file non ingeriti).

**Gate 2 superato:** formati identificati da Siegfried 1.11.2 (25 Microsoft Excel su DP08SC, più PDF, CSV, JSON, Plain Text), nessun Unknown, nessun Tab-Separated Values. Su PKZ7FJ 2 eventi di `normalization` con 2 derivate PDF/A validate. I 25 nomi con spazi risultano sanificati sul filesystem e documentati in `originalName` con relativi eventi `filename change`.

#### Anomalie riscontrate e risolte durante il pilota:

1. *Ingest fallito con i pacchetti in sottocartella* (`Filepath ... does not exist`): bug di `archivematica_ingest.py`, che ricostruiva il percorso dal solo nome della cartella perdendo la sottocartella. Corretto passando il path assoluto del pacchetto; verificato con un transfer completato da sottocartella.
2. *Tutti i formati Unknown al primo ingest*: identificazione dei formati disattivata nella processing configuration (vedi prerequisito 4.7). Corretta e ingest ripetuto.
3. *Permessi in scrittura sulla Transfer Source*: il mount `drvfs` usa `uid=333;gid=333;umask=022`, quindi al gruppo manca il bit `w`. Risolto con `chmod g+ws` sulla cartella; per il lotto va valutata una soluzione stabile (`umask=002` in `/etc/wsl.conf` o riposizionamento della location).

### 13.2 Esito della calibrazione sul primo lotto reale (LOTTO\_27)

111 DOI leggeri (118 file, 2 GB): **110 ingeriti, 1 fallito**, 75,5 minuti, media 41,6 s per pacchetto (vedi 11.1).

Il caso fallito — un dataset composto da un unico archivio compresso da 610 MB — ha fatto emergere tre problemi a catena, tutti documentati nella sezione 9: la domanda *Extract packages?* non coperta dalla configurazione (9.1), il disallineamento di MCPClient dopo il riavvio di MCPServer (9.2) e il riaggancio di un transfer annullato rimasto nel file di stato (9.3).

**Lezione per il lotto completo:** un solo caso su 111 è circa lo 0,9%, che sui 672 pacchetti significherebbe una sessantina di transfer bloccati. Il censimento preventivo con `censisci_archivi.py` ha poi individuato **39 dataset con archivi compressi** (12 043 archivi, 11,88 GB), portando alla revisione della politica di estrazione documentata nella sezione 10.

Da questo caso è emerso anche che il piano dei lotti **sottostima sistematicamente** i dataset contenenti archivi: WPOXS5 risultava «1 file, 0,58 GB» e ha prodotto **2 238 elementi** nell'AIP (1 859 eventi di

unpacking), perché conteneva un archivio NMR con una gerarchia profonda 10 livelli. I lotti che contengono dataset con archivi vanno quindi considerati più pesanti di quanto il conteggio dei file suggerisca.