

# Ri-acquisizione del corpus Dataverse — Runbook del pilota (Fase 1)

Direzione ICT, Università degli Studi di Milano — Progetto Arkive

Luglio 2026

## Indice

|                                                                     |          |
|---------------------------------------------------------------------|----------|
| <b>Runbook del pilota — Fase 1</b>                                  | <b>2</b> |
| 1. Scopo e contesto                                                 | 2        |
| 2. Esito della Fase 0 (dati di partenza)                            | 2        |
| 3. Dataset pilota selezionati                                       | 2        |
| 4. Prerequisiti (da verificare PRIMA di iniziare)                   | 3        |
| 5. Esecuzione                                                       | 4        |
| 5.1 Camera pulita — DENTRO la Transfer Source Location              | 4        |
| 5.2 Lista DOI del pilota                                            | 4        |
| 5.3 Download                                                        | 4        |
| 6. Gate 1 — Validazione dell’acquisizione                           | 4        |
| 7. Ingest e Gate 2 — Validazione dell’AIP                           | 6        |
| 7.1 Ingest                                                          | 6        |
| 7.2 Gate 2 — controlli sull’AIP                                     | 7        |
| 8. I 7 DOI non più raggiungibili                                    | 8        |
| 8.1 Come si accerta che un DOI è davvero scomparso                  | 8        |
| 8.2 Lo scope va verificato, non dato per acquisito                  | 9        |
| 9. Blocchi durante l’ingest — diagnosi e rimedi                     | 9        |
| 9.1 Transfer fermo in <code>USER_INPUT</code>                       | 9        |
| 9.2 Nessun job avanza: <code>MCPClient</code> disallineato          | 9        |
| 9.3 Lo script riaggancia un transfer annullato                      | 10       |
| 9.4 Procedura completa di ripartenza pulita                         | 10       |
| 10. Politica di trattamento degli archivi compressi                 | 10       |
| 10.1 Il problema                                                    | 11       |
| 10.2 Verifica empirica                                              | 11       |
| 10.3 Verifica del doppio passaggio sui <code>.tar.gz</code>         | 11       |
| 10.4 Decisione adottata: configurazione differenziata a due lotti   | 12       |
| 10.5 Applicazione e verifica                                        | 12       |
| 11. Export dei metadati per versione: limite noto dell’istanza      | 13       |
| 12. Piano dei lotti e calibrazione                                  | 13       |
| 12.1 Dati di calibrazione misurati                                  | 14       |
| 12.2 Stima dell’intera ri-acquisizione                              | 14       |
| 13. Criteri di GO / NO-GO per il lotto completo                     | 14       |
| 14. Registrazione dell’esito                                        | 15       |
| 14.1 Esito del pilota del 22 luglio 2026                            | 15       |
| 14.3 Esito del LOTTO_14 (calibrazione del costo per file)           | 16       |
| 14.2 Esito della calibrazione sul primo lotto reale (LOTTO_27)      | 16       |
| 15. Fase 2 — Ambiente dedicato e migrazione degli AIP in produzione | 16       |
| 15.1 Impostazione                                                   | 16       |
| 15.2 Cosa si perde svuotando l’istanza                              | 16       |
| 15.3 Ricollocare la Transfer Source fuori da Dropbox                | 17       |

|                                                        |    |
|--------------------------------------------------------|----|
| 15.4 Procedura di ripartenza pulita . . . . .          | 17 |
| 15.5 Test di migrazione: un AIP prima di 671 . . . . . | 17 |
| 15.6 Criterio di chiusura della Fase 2 . . . . .       | 18 |

## Runbook del pilota — Fase 1

### 1. Scopo e contesto

Il corpus Dataverse è stato acquisito e ingerito in Archivematica **prima** che la pipeline introducesse due comportamenti oggi ritenuti necessari:

1. la **verifica di integrità** dei file scaricati (checksum/dimensione), che impedisce a un download troncato di entrare silenziosamente nel SIP;
2. la **conservazione dell'originale** per i file ingeriti come tabellari (`format=original`), invece della derivata `.tab` generata da Dataverse.

Poiché gli AIP prodotti finora sono **sperimentali** (progetto in fase avanzata ma non ancora in produzione), è stato deciso di **non migrare** i pacchetti esistenti ma di **ri-acquisire l'intero corpus** con la pipeline corretta e ricostruire gli AIP da una baseline pulita. Questo evita di trascinare nella futura produzione catene di supersede e record di deaccession relativi a materiale di prova, e — cosa più importante — sottopone a verifica di integrità **tutto** il corpus, non solo i dataset con l'anomalia nota.

Questo documento descrive la **Fase 1**: l'esecuzione controllata del ciclo completo su **due dataset pilota**, allo scopo di validare la procedura prima di applicarla all'intero scope; la **sezione 15** documenta l'impostazione della Fase 2, ossia la lavorazione su workstation dedicata e la successiva migrazione degli AIP sull'istanza di produzione. Il prodotto della Fase 1 non è solo “due pacchetti corretti”, ma **la procedura verificata** da ripetere sul lotto.

### 2. Esito della Fase 0 (dati di partenza)

La ricognizione con `verifica_raggiungibilita.py` sui 708 DOI dello scope ha dato:

| Indicatore                                    | Valore          |
|-----------------------------------------------|-----------------|
| DOI ri-acquisibili (OK)                       | <b>671</b>      |
| DOI vuoti (nessun file in nessuna versione)   | 30              |
| DOI <b>non più raggiungibili</b> su Dataverse | <b>7</b>        |
| DOI con file ad accesso ristretto             | 111             |
| Versioni totali da scaricare                  | 1 226           |
| File totali da scaricare                      | 67 730          |
| Volume stimato (originali, tutte le versioni) | <b>62,95 GB</b> |

I 7 DOI non più raggiungibili — QA4BR0, BX8AIN, YF2NZV, WKMYTV, YIAURF, OYDM83, ZYY5RK — sono **fuori dallo scope della ri-acquisizione** e vanno trattati a mano: vedi sezione 8. Il settimo (ZYY5RK) risultava disponibile in Fase 0 ed è scomparso durante la lavorazione: lo scope va riverificato lotto per lotto (sezione 8.2).

### 3. Dataset pilota selezionati

I due pilota sono scelti per **esercitare i percorsi nuovi**, non per comodità:

| Pilota   | DOI                          | Versioni | File | Ingeriti | Ristretti | Volume |
|----------|------------------------------|----------|------|----------|-----------|--------|
| <b>A</b> | doi:10.13130/RD_UNIMI/PKZ7FJ | 4        | 10   | 8        | 0         | 4,3 MB |
| <b>B</b> | doi:10.13130/RD_UNIMI/DP08SC | 3        | 26   | 23       | 25        | 1,1 MB |

**Perché A:** quattro versioni e otto file ingeriti su dieci. Valida in un colpo solo la struttura per versione (objects/<versione>/objects/), il download `format=original` e l'identificazione dei formati reali, restando piccolo.

**Perché B:** quasi tutti i file sono **contemporaneamente ristretti e ingeriti** (25 ristretti, 23 ingeriti su 26). È l'intersezione più rischiosa dell'intero corpus: richiede che `format=original` funzioni **su file ad accesso ristretto con API key**. Se in quella combinazione mancasse un permesso, il pacchetto risulterebbe silenziosamente incompleto su una parte significativa dei 111 DOI ristretti.

## 4. Prerequisiti (da verificare PRIMA di iniziare)

Nessuno di questi punti è formale: ognuno corrisponde a un incidente già occorso.

**4.1 Sincronizzazione Dropbox disattivata sulla cartella di lavoro.** Per il pilota è sufficiente la sospensione della sincronizzazione. Per il lotto completo va valutata la Selective Sync o lo spostamento della cartella fuori da Dropbox (vedi sezione 9).

**4.2 Mount drvfs con opzione metadata.** Senza di essa `utime()` fallisce e lo store dell'AIP termina con errore `rsync` codice 23 anche quando il trasferimento dei file è riuscito. Verifica:

```
mount | grep drvfs
# atteso: ... type drvfs (rw,noatime,...,metadata,uid=...,gid=...,umask=022)
cat /etc/wsl.conf
```

**4.3 Spazio disponibile.** Per il pilota bastano pochi MB, ma è il momento giusto per misurare l'headroom in vista del lotto (63 GB di download più lavorazione Archivematica e AIP risultanti):

```
df -h /mnt/e
```

**4.4 File .env completo,** con `DATAVERSE_API_KEY` valorizzata: **indispensabile** per il Pilota B (file ristretti). Verifica rapida senza stampare la chiave:

```
cd tools/dataverse-archivematica
grep -c DATAVERSE_API_KEY .env # atteso: 1
```

**4.5 Utente di esecuzione.** Gli script della pipeline **non vanno mai eseguiti come utente archivematica**. Verifica con `whoami`.

**4.6 Versione degli script.** Il pilota ha senso solo con la pipeline aggiornata:

```
git log --oneline -1
grep -c "_is_ingested_tabular" scarica_dataverse.py # atteso: >= 2
grep -c "doi_path.resolve()" archivematica_ingest.py # atteso: 1
```

**4.7 Processing configuration corretta — condizione critica.** Due scelte di `dataverse_001` determinano la qualità archivistica degli AIP:

| Decisione                                              | Valore richiesto                  |
|--------------------------------------------------------|-----------------------------------|
| Perform file format identification ( <b>Transfer</b> ) | <b>Yes</b>                        |
| Perform file format identification (Ingest)            | <i>No, use existing data</i>      |
| <b>Normalize</b>                                       | <b>Normalize for preservation</b> |
| Approve normalization                                  | Yes                               |

Senza identificazione in fase di transfer, il METS riporta Unknown per **tutti** gli oggetti: niente PUID, niente pianificazione della conservazione, e la normalizzazione non può funzionare (il FPR sceglie le regole in base al formato riconosciuto). L'impostazione "*No, use existing data*" in ingest è corretta solo se l'identificazione in transfer è attiva, altrimenti non esistono dati da riusare.

Il file **non va modificato a mano**: gli UUID delle catene variano tra versioni di Archivematica. Si genera dal Dashboard (*Administration -> Processing configuration -> dataverse\_001 -> Edit -> Save -> Download*) e si copia nella posizione della copia locale versionata. Verifica:

```
CFG=~/.arkive/config/dataverse_001ProcessingMCP.xml
grep -A2 "f09847c2-ee51-429a-9478-a860477f6b8d" $CFG # identificazione: NON "Skip"
grep -A2 "cb8e5706-e73f-472f-ad9b-d1236af8095f" $CFG # normalizzazione
grep -A2 "7509e7dc-1e1b-4dce-8d21-e130515fce73" $CFG # normalizzazione (2° punto)
```

## 5. Esecuzione

### 5.1 Camera pulita — DENTRO la Transfer Source Location

La ri-acquisizione **non** si sovrappone a cartelle esistenti: la pipeline salva ora i nomi originali (.csv, .dta), quindi su una cartella popolata in passato scaricherebbe gli originali **accanto** ai vecchi .tab, lasciando entrambi.

La cartella di lavoro deve inoltre trovarsi **fisicamente dentro il percorso della Transfer Source Location** dello Storage Service. Motivo: `archivematica_ingest.py` avvia il transfer passando `base64(<location_uuid>:<path_a` e lo Storage Service accetta solo percorsi interni alla location. Un pacchetto fuori da lì non verrebbe visto da Archivematica.

Allo stesso tempo la cartella deve essere una **sottocartella dedicata**, non la radice della Transfer Source: se si omette `--source`, lo script raccoglie *tutti* i pacchetti DOI presenti nella location, compresi quelli della vecchia acquisizione, che il pilota non deve toccare.

```
# 1) ricavare il percorso della Transfer Source Location (o usare quello noto)
TS_PATH=/percorso/della/transfer_source # adattare
```

```
# 2) creare la sottocartella dedicata al pilota, vuota
mkdir -p "$TS_PATH/PILOTA"
ls -A "$TS_PATH/PILOTA" # deve essere vuota
```

Se il download è già stato eseguito altrove, spostare i pacchetti (non copiarli, per non lasciare duplicati):

```
mv PILOTA/doi_* "$TS_PATH/PILOTA"/
```

### 5.2 Lista DOI del pilota

```
cat > dois_pilota.txt << 'EOF'
doi:10.13130/RD_UNIMI/PKZ7FJ
doi:10.13130/RD_UNIMI/DP08SC
EOF
```

### 5.3 Download

```
python3 scarica_dataverse.py --dois dois_pilota.txt --output "$TS_PATH/PILOTA" --dcat \
2>&1 | tee logs/pilota_download.log
```

`--dcat` è necessario: il pilota deve validare anche che la `dcat:distribution` descriva l'originale.

## 6. Gate 1 — Validazione dell'acquisizione

**Non procedere all'ingest se anche uno solo di questi controlli fallisce.**

**6.1 Nessun errore di download.** Nel `riepilogo_download.json` entrambi i DOI devono risultare ok, mai partial:

```
python3 -c "
import json,os; TS=os.environ['TS_PATH']
```

```
d=json.load(open(TS+' /PILOTA/riepilogo_download.json'))
print(json.dumps(d, indent=2)[:800])
"
grep -c "ERRORE\\|\\[RISCARICO\\]" logs/pilota_download.log # atteso: 0
```

**6.2 Nessun fallback alla derivata.** Se compare [FALLBACK], per quel file format=original non ha risposto e nel pacchetto è finita la .tab:

```
grep "\\[FALLBACK\\]" logs/pilota_download.log # atteso: nessun risultato
```

Controllo di contabilità speculare, che conferma il caso positivo:

```
grep -c "Scarico:" logs/pilota_download.log # atteso: 36 (10 + 26)
grep -c "originale di" logs/pilota_download.log # atteso: 31 (8 + 23)
```

Il primo è il totale dei file scaricati, il secondo quelli scaricati **come originale** al posto della derivata (etichetta nome.csv (originale di nome.tab)). La differenza (36 – 31 = 5) deve corrispondere ai file **non** ingeriti, cioè privi di un originale distinto. Se la contabilità non chiude, qualche file ingerito non è stato trattato come tale e va indagato prima di procedere.

**6.3 Sono stati conservati gli ORIGINALI, non i .tab.** È il controllo centrale del Livello 2:

```
find "$TS_PATH/PILOTA" -name "*.tab" | head # atteso: NESSUN risultato
find "$TS_PATH/PILOTA" -path "*/objects/*" -type f -not -path "*/metadata/*" | head -20
```

**I nomi vanno preservati esattamente come depositati.** Nell'elenco è normale — e corretto — trovare nomi con spazi (IVD\_NMBU shipment 2\_cytotoxicity\_NRU.xlsx) o con estensioni anomale ripetute (...\_ANPEP.xlsx.xlsx). La pipeline usa originalFileName così com'è: quei nomi sono letteralmente quelli con cui il ricercatore ha depositato i file. Conservarli invariati, refusi compresi, è il comportamento corretto ai fini dell'autenticità dell'oggetto archiviato; una normalizzazione silenziosa produrrebbe oggetti diversi dagli originali.

**6.4 Struttura per versione completa.** Il Pilota A deve avere 4 versioni, il Pilota B 3:

```
ls -d "$TS_PATH"/PILOTA/*PKZ7FJ*/objects/* # atteso: 4 directory
ls -d "$TS_PATH"/PILOTA/*DP08SC*/objects/* # atteso: 3 directory
ls "$TS_PATH"/PILOTA/*DP08SC*/objects/*/metadata/
```

**Asimmetria attesa nei metadati di versione:** dataverse.json, dcat.json e metadata.csv sono presenti in **ogni** versione perché generati localmente dalla pipeline; schema.json compare **solo nell'ultima versione**, perché è scaricato dall'exporter Schema.org di Dataverse, che lavora a livello di dataset e non espone le versioni storiche. La sua assenza nelle versioni precedenti **non è un errore di export**. Da verificare invece se mancasse in modo irregolare (per esempio assente anche nell'ultima versione, o presente a intermittenza).

**6.5 I file ristretti sono stati scaricati (Pilota B).** Contro il rischio del pacchetto silenziosamente incompleto: il numero di file di dati presenti su disco deve corrispondere a quello atteso dal report di Fase 0.

```
find "$TS_PATH"/PILOTA/*DP08SC* -path "*/objects/*" -type f \
-not -path "*/metadata/*" | wc -l # atteso: 26
```

L'esclusione di \*/metadata/\* è necessaria: nella struttura objects/<versione>/metadata/ la parola objects compare comunque nel percorso, quindi senza il filtro verrebbero conteggiati anche dcat.json, metadata.csv, dataverse.json e schema.json, falsando il totale.

**6.6 Il DCAT descrive l'originale.**

```
python3 -c "
import json,glob,os
TS=os.environ['TS_PATH']
for p in sorted(glob.glob(TS+' /PILOTA/*/objects/*/metadata/dcat.json'))[:2]:
    d=json.load(open(p)); dd=d.get('dcat:distribution')
    dd=dd if isinstance(dd,list) else [dd]
```

```

print(p)
for x in dd[:3]:
    print(' ', x.get('dct:title'), '|', x.get('dcat:mediaType'), '|',
          x.get('dcat:accessURL',{}).get('@id','')[-30:])
"

```

Atteso: titoli con estensione originale (.csv, .xlsx, .dta), mediaType dell'originale (**non** text/tab-separated-values) e accessURL che termina con ?format=original.

**Attenzione** — è normale che alcune accessURL NON abbiano ?format=original. La pipeline decide file per file: i file **non ingeriti** da Dataverse (privi dei campi original\*) non hanno una rappresentazione originale distinta, quindi il loro accessURL è quello semplice. Aggiungere ?format=original significherebbe descrivere una rappresentazione inesistente. Un .xlsx può benissimo non essere stato ingerito (fogli multipli, dimensione, ingest non riuscito): non è un errore.

Verifica di contabilità sull'intero pilota, che chiude il cerchio con il log:

```

python3 - << 'EOF'
import json, glob, os
TS=os.environ['TS_PATH']
tot=orig=plain=0
for p in sorted(glob.glob(TS+'/*PILOTA/*/objects/*/metadata/dcat.json')):
    d=json.load(open(p)); dd=d.get('dcat:distribution') or []
    dd=dd if isinstance(dd,list) else [dd]
    for x in dd:
        tot+=1
        u=x.get('dcat:accessURL',{}).get('@id','')
        if u.endswith('?format=original'): orig+=1
        else: plain+=1
        if 'tab-separated' in (x.get('dcat:mediaType') or ''):
            print('!! ANOMALIA (mediaType .tab):', p, x.get('dct:title'))
print(f"distribution totali: {tot} con format=original: {orig} senza: {plain}")
EOF

```

Atteso: **36 totali, 31 con format=original, 5 senza** — gli stessi numeri dei grep del punto 6.2. Nessuna riga di anomalia. In caso di dubbio su un singolo file, la conferma si legge in dataverse.json: se originalFileName e originalFileFormat sono None, il file non è ingerito e l'URL semplice è corretto.

**6.7 metadata.csv coerente.** La colonna filename è costruita leggendo il disco, quindi deve elencare i nomi originali:

```
head -3 "$TS_PATH"/PILOTA/*PKZ7FJ*/metadata/metadata.csv
```

## 7. Ingest e Gate 2 — Validazione dell'AIP

### 7.1 Ingest

```
python3 archivematica_ingest.py --source "$TS_PATH/PILOTA" --auto-approve \
--state-file stato_pilota.json 2>&1 | tee logs/pilota_ingest.log
```

Due accorgimenti, entrambi necessari:

- **--source esplicito.** Omettendolo, lo script userebbe la radice della Transfer Source Location e raccoglierebbe *tutti* i pacchetti DOI presenti, inclusi quelli della vecchia acquisizione: il pilota ingerirebbe molto più del previsto. Puntando alla sottocartella si lavora solo sui due dataset.
- **File di stato separato** (stato\_pilota.json), per non mescolare il pilota con lo storico di produzione in stato\_archivematica.json.

Prima di lanciare, verificare che nella sottocartella ci siano esattamente i due pacchetti attesi:

```
ls -d "$TS_PATH/PILOTA"/doi_*          # atteso: 2 directory
```

## 7.2 Gate 2 — controlli sull'AIP

**7.2.1 AIP presente e memorizzato.** Annotare gli UUID e verificare lo stato:

```
python3 - << 'EOF'
import os, requests, urllib3
urllib3.disable_warnings()
for l in open('.env'):
    l=l.strip()
    if l and not l.startswith('#') and '=' in l:
        k,_,v=l.partition('='); os.environ.setdefault(k.strip(), v.strip().strip('"\''))
SS=os.environ.get('SS_URL', 'http://localhost:8000')
H={'Authorization': f"Apikey {os.environ['SS_USER']}:{os.environ['SS_API_KEY']}"}
for nome,uuid in [( 'DP08SC', '<AIP-UUID>' ), ( 'PKZ7FJ', '<AIP-UUID>' )]:
    d=requests.get(f"{SS}/api/v2/file/{uuid}/", headers=H, verify=False, timeout=60).json()
    print(f"{nome}: status={d.get('status')} size={d.get('size')}")
    print(f"    {d.get('current_full_path')}")
EOF
```

Atteso: `status=UPLOADED`. Le dimensioni devono essere coerenti con il volume degli originali stimato in Fase 0.

**7.2.2 Formati, eventi e agenti — il controllo decisivo.** Legge il METS dall'AIP compresso senza estrarlo:

```
python3 - << 'EOF'
import tarfile, glob, re
from collections import Counter
import xml.etree.ElementTree as ET
for uuid, nome in [( '<primi8>', 'DP08SC' ), ( '<primi8>', 'PKZ7FJ' )]:
    aip = glob.glob(f"/mnt/e/ARKIVE/AIPsStore/{uuid[:4]}/**/*{uuid}*.tar.gz", recursive=True)
    with tarfile.open(aip[0]) as t:
        mets=[m for m in t.getnames() if re.search(r'/data/METS/.*\.xml$', m)]
        xml=t.extractfile(mets[0]).read()
        root=ET.fromstring(xml); tag=lambda e: e.tag.split(' ')[-1]
        print(f"\n=== {nome}")
        for f,n in Counter(e.text for e in root.iter() if tag(e)=='formatName').most_common():
            print(f"    {n:4d}  {f}")
        for e,n in Counter(x.text for x in root.iter() if tag(x)=='eventType').most_common():
            print(f"    [ev] {n:4d}  {e}")
EOF
```

Attesi e criteri di lettura:

- i formati devono essere **identificati**: Microsoft Excel, CSV, Plain Text, JSON Data Interchange Format... e **nessun Unknown**;
- **nessun Tab-Separated Values** tra gli oggetti: se comparisse, nell'AIP è finita una derivata invece dell'originale;
- deve esserci un evento **format identification** per ogni oggetto;
- gli eventi **normalization** compaiono **solo per i formati con una regola FPR** (tipicamente PDF, immagini, audio, video). La loro assenza sugli .xlsx non è un guasto: il FPR considera quei formati già adeguati alla conservazione;
- l'agente e la versione dello strumento di identificazione si leggono nell'`eventDetail` (es. `program="Siegfried"; version="1.11.2"`).

**7.2.3 Conteggio degli oggetti — attenzione a cosa si conta.** Il numero di file nel METS è **maggiore**

di quello dei file di dati, perché i metadati per versione (`objects/vX.Y/metadata/...`) stanno dentro `objects/` e Archivematica li tratta come contenuto. Per DP08SC: 26 file di dati + 10 metadati = 36; per PKZ7FJ: 10 + 13 = 23. Solo la cartella `metadata/` di primo livello è trattata come metadati descrittivi.

**7.2.4 Nomi originali preservati.** Archivematica **sanifica** i nomi con spazi o caratteri problematici sul filesystem e registra ogni modifica con un evento `filename change`. Il nome di deposito resta documentato nel METS in `originalName`. Verifica che gli spazi ci siano ancora:

```
python3 - << 'EOF'
import tarfile, glob, re
import xml.etree.ElementTree as ET
uuid='<primi8>'
aip=glob.glob(f"/mnt/e/ARKIVE/AIPsStore/{uuid[:4]}/**/*{uuid}*.tar.gz", recursive=True)
with tarfile.open(aip[0]) as t:
    mets=[m for m in t.getnames() if re.search(r'/data/METS\\.\\.\\.\\.xml$', m)]
    xml=t.extractfile(mets[0]).read()
    root=ET.fromstring(xml); tag=lambda e: e.tag.split(' ')[-1]
    orig=[e.text for e in root.iter() if tag(e)=='originalName' and e.text and not e.text.endswith('/')]
    print("con spazi nel nome:", sum(1 for o in orig if ' ' in o.split('/')[1]), "su", len(orig))
EOF
```

**7.2.5 Fixity.** Nessun evento PREMIS di *fixity check* fallito.

## 8. I 7 DOI non più raggiungibili

QA4BR0, BX8AIN, YF2NZV, WKMYTV, YIAURF, OYDM83 e ZYY5RK non esistono più su `dataverse.unimi.it`. Per questi la ri-acquisizione è **impossibile**, quindi:

1. **Prima di qualunque pulizia**, verificare se ne esiste una copia locale (nelle cartelle di download o negli AIP già prodotti) e, in caso affermativo, **metterla al sicuro fuori dall'area di lavoro**: sarebbe l'unico esemplare rimasto.
2. **Segnalare la scomparsa ai responsabili di Data@UNIMI**. Sette dataset pubblicati con DOI assegnato che spariscono da un repository certificato CoreTrustSeal richiedono una spiegazione (deaccession su richiesta dell'autore, DOI di test rimossi, o altro), che va documentata. Nel browser tutti e sette restituiscono *"Page Not Found"* e non una pagina di deaccession: si tratta quindi di **eliminazione**, non di ritiro tracciato.
3. Non includerli nelle liste dei lotti.

### 8.1 Come si accerta che un DOI è davvero scomparso

**Un 404 isolato non è una prova.** Sotto rate limiting `dataverse.unimi.it` risponde 404 con lo stesso identico corpo JSON di un dataset realmente inesistente:

```
{"status": "ERROR", "message": "When accessing a dataset based on Persistent ID,
a persistentId query parameter must be present."}
```

I due casi sono **indistinguibili per contenuto**: stesso status, stesso content-type, stesso messaggio. La prova è che JMKS AW, che è vivo e da cui abbiamo scaricato migliaia di file, interrogato in raffica risponde 404 con quel corpo e interrogato in isolamento risponde 200.

L'unico discriminante affidabile è la **ripetizione con pausa**: un dataset inesistente risponde 404 a ogni tentativo, il throttling cede. Gli strumenti `verifica_raggiungibilita.py` e `censisci_archivi.py` dichiarano perciò un dataset irraggiungibile solo se il 404 si ripete su **tutti** i tentativi.

Verifica manuale di conferma, prima di dichiarare perso un dataset:

```
set -a; source .env; set +a
for i in 1 2 3; do
    sleep 6
```

```
curl -s -o /tmp/z.txt -w "tentativo $i -> HTTP %{http_code}\n" \
-H "X-Dataverse-key: ${DATAVERSE_API_KEY}" \
"https://dataverse.unimi.it/api/datasets/:persistentId/versions?persistentId=<DOI>"
done
```

Tre 404 con pause di 6 secondi, più il controllo nel browser, sono la combinazione che è stata usata per accertare i sette casi.

**Prima applicazione del criterio sbagliato:** con la regola iniziale («404 + corpo JSON di Dataverse = rimozione») il censimento aveva classificato come irraggiungibili **28 DOI**, di cui 22 erano falsi positivi da throttling, compreso VHW2QV con 2 544 file. È il motivo per cui il criterio è stato corretto.

## 8.2 Lo scope va verificato, non dato per acquisito

ZYY5RK risultava OK con 3 file nella ricognizione di Fase 0 ed è scomparso **nell’arco di due giorni**, durante la lavorazione stessa. Lo scope non è quindi un dato stabile: conviene **riverificare i DOI di ogni lotto poco prima di lavorarlo**, invece di fidarsi di una ricognizione fatta una volta sola.

Quando un DOI risulta perso a piano già generato, va rimosso dalle liste:

```
grep -l "<SIGLA>" lotti/*.txt
sed -i '/<SIGLA>/d' lotti/*.txt
echo "doi:10.13130/RD_UNIMI/<SIGLA>" >> doi_non_raggiungibili.txt
```

## 9. Blocchi durante l’ingest — diagnosi e rimedi

Questi casi si sono presentati tutti durante la calibrazione del primo lotto e sono destinati a ripresentarsi su 27 lotti. Vanno riconosciuti in fretta perché, a colpo d’occhio, si somigliano molto: lo script attende, il transfer risulta PROCESSING, e apparentemente “non succede nulla”.

### 9.1 Transfer fermo in USER\_INPUT

Archivematica ha incontrato una decisione **non coperta** dalla `processingMCP.xml` e attende una risposta. L’opzione `--auto-approve` gestisce solo l’approvazione iniziale del transfer, non le scelte successive.

Il caso riscontrato: un dataset composto da un unico archivio compresso ha fatto comparire la domanda **“Extract packages?”**, assente dalla configurazione. La soluzione non è rispondere a mano — su 672 pacchetti si ripresenterebbe decine di volte — ma **aggiungere la scelta alla processing configuration** e rilanciare.

Impostazione adottata: **Extract packages = Yes, Delete packages after extraction = No**. In questo modo l’AIP contiene sia l’archivio originale come depositato (autenticità) sia il contenuto estratto, identificato, verificato e normalizzato (conservazione effettiva). Conservare un archivio non estratto significherebbe custodire un oggetto opaco: nessuna identificazione dei formati interni, nessun monitoraggio dell’obsolescenza, nessuna normalizzazione possibile.

**Il `processingMCP.xml` viene letto all’AVVIO del transfer.** Aggiornare la configurazione mentre un transfer è in corso non ha alcun effetto su quel transfer: va annullato e riavviato. Verificare inoltre che il file **dentro il pacchetto** sia quello nuovo (lo script lo ricopia a ogni esecuzione, ma un transfer già avviato usa la copia letta in partenza).

### 9.2 Nessun job avanza: MCPClient disallineato

Sintomo: `[approve]` Nessun transfer in attesa trovato ripetuto, poi `[transfer]` stato: PROCESSING all’infinito. In Dashboard il transfer non progredisce.

Causa: dopo aver **fermato e riavviato MCPServer** (operazione necessaria per pulire le watched directory), MCPClient resta agganciato alla sessione Gearman precedente e smette di prelevare i job. Il server li accoda, nessuno li esegue.

L'insidia è che tutti i servizi risultano **active**: il segnale vero è il **disallineamento degli orari di avvio** e l'assenza di righe recenti **\*\*\* RUNNING TASK: ... \*\*\*** nel log del client.

```
systemctl status archivematica-mcp-server archivematica-mcp-client gearman-job-server
sudo journalctl -u archivematica-mcp-client -n 30 --no-pager
```

**Regola operativa: dopo ogni riavvio di MCPServer, riavviare anche MCPClient.**

```
sudo systemctl start archivematica-mcp-server
sudo systemctl restart archivematica-mcp-client
```

### 9.3 Lo script riaggancia un transfer annullato

Sintomo: nel log compare **Transfer UUID (ripresa): <uuid>** seguito da tentativi di approvazione che non trovano mai nulla. Lo script non sta avviando un transfer nuovo: sta cercando di riprendere quello registrato nel file di stato, che nel frattempo è stato annullato dalla Dashboard e quindi non comparirà mai tra i transfer in attesa.

È il rovescio del meccanismo di ripresa (`find_transfer_uuid_by_name`), utile dopo un timeout di rete ma dannoso quando il transfer è stato eliminato di proposito.

**Rimedio: annullando un transfer dalla Dashboard, rimuovere anche la voce corrispondente dal file di stato**, così il DOI riparte da zero.

```
cp stato_riacquisizione.json stato_riacquisizione.json.bak
python3 - << 'EOF'
import json
p='stato_riacquisizione.json'; d=json.load(open(p))
k='doi_10.13130_RD_UNIMI_XXXXXX'          # adattare
if k in d:
    print("rimuovo:", d.pop(k)); json.dump(d, open(p,'w'), indent=2, ensure_ascii=False)
print("voci rimaste:", len(d))
EOF
```

Al rilancio il log deve mostrare **Avvio transfer '...' con un UUID nuovo**, non più **Transfer UUID (ripresa)**.

### 9.4 Procedura completa di ripartenza pulita

Quando un pacchetto va rifatto da zero, l'ordine conta:

1. interrompere lo script (Ctrl-C: lo stato è già su disco);
2. annullare il transfer dalla Dashboard;
3. `sudo systemctl stop archivematica-mcp-server`;
4. rimuovere le copie residue del pacchetto dalle watched directory (`sudo find /var/archivematica/sharedDirectory/watched -maxdepth 3 -name "*<DOI>*"`);
5. `sudo systemctl start archivematica-mcp-server` e `sudo systemctl restart archivematica-mcp-client`;
6. rimuovere la voce del DOI dal file di stato (9.3);
7. verificare che il `processingMCP.xml` nel pacchetto sia quello aggiornato;
8. rilanciare lo stesso comando di ingest.

## 10. Politica di trattamento degli archivi compressi

Questa sezione documenta una **decisione di politica di conservazione**, presa durante il pilota sulla base di verifiche empiriche. Va conservata come tale: non è un dettaglio di configurazione, ma una scelta che determina la forma degli oggetti conservati e che va poter essere motivata in sede di audit.

## 10.1 Il problema

Con `Extract packages = Yes` Archivematica estrae gli archivi e tratta ogni file interno come oggetto autonomo. La scelta è stata attivata perché conservare un archivio non estratto significa custodire un oggetto **opaco**: nessuna identificazione dei formati interni, nessun monitoraggio dell'obsolescenza, nessuna normalizzazione possibile.

Il censimento dello scope (`censisci_archivi.py`) ha però mostrato che i file riconosciuti come “archivio” appartengono a **due categorie molto diverse**:

| Categoria                     | Esempi                                                   | L'estrazione è...                                              |
|-------------------------------|----------------------------------------------------------|----------------------------------------------------------------|
| <b>Contentori veri</b>        | FIBRE.zip, Output.zip, MARBLE.rar, qcr_instances.tgz     | <b>utile</b> : dentro c'è una gerarchia di file identificabili |
| <b>File singoli compressi</b> | *.rds (serializzazioni R), *.Rdata, *.fastq.gz, *.sql.gz | <b>dannosa</b> : produce un blob non utilizzabile              |

Un `.rds` non è un contenitore: è il formato nativo di R, compresso con gzip. Dataverse ne dichiara il `contentType` come `application/gzip` e Siegfried lo identifica come **GZip (PUID x-fmt/266)**, quindi la regola di estrazione del FPR si attiva.

## 10.2 Verifica empirica

Test su `doi:10.13130/RD_UNIMI/HADWPV` (3 file, di cui un `.rds` da 814 KB), METS dell'AIP risultante:

- **1 evento unpacking** → il `.rds` è stato effettivamente estratto;
- tra i formati compare **1 Unknown** → il contenuto estratto è la serializzazione R grezza, che nessun registro di formati riconosce;
- oggetti totali 11 anziché 10.

L'estrazione produce quindi **zero guadagno di conservazione**: da un `.rds` valido esce un blob inservibile senza il wrapper. L'originale resta (grazie a `Delete packages after extraction = No`), ma accanto vi è un duplicato inutile.

**Impatto sullo scope**: i dataset a base `.rds` sommano circa **11 500 file** (NZRX1C 6 615, PLHGBP 1 620, UGSD3F 1 620, UZ25HQ 1 080, V0TP76 285, 1MZNNS 180 e altri). L'estrazione ne genererebbe circa **23 000** anziché 11 500, con il relativo tempo di processing e nessun beneficio. Sui `.fastq.gz` si aggiungerebbe una forte crescita di spazio, dato che il formato compresso è la forma standard di distribuzione dei dati di sequenziamento.

## 10.3 Verifica del doppio passaggio sui `.tar.gz`

Prima di decidere è stato accertato **come Archivematica tratta i veri archivi `.tar.gz`**, perché da questo dipende la portata della scelta.

**Siegfried non distingue i due casi**. Su un `.tar.gz` contenente una directory e su un banale `.txt.gz`, l'identificazione è identica:

```
id: x-fmt/266   format: GZIP Format   basis: extension match gz; byte match at 0, 3
```

È una conseguenza strutturale del formato: gzip comprime un flusso singolo e la sua signature sta nei primi byte; cosa contenga si scopre solo decomprimendo. **Nessuna regola FPR può separare i due casi**, perché il FPR ragiona per PUID e il PUID è lo stesso.

**L'estrazione avviene però in due passaggi**. Test su `doi:10.13130/RD_UNIMI/IHTWC0` (4 versioni, un `.tar.gz` da 17,9 MB ciascuna), METS dell'AIP risultante:

- formati: **4 GZip e 4 TAR** — uno per versione;
- percorsi annidati che documentano la catena: `STSWSN-PC_INSTANCES.tar-1.gz-<timestamp>/STSWSN-PC_INSTANCES.tar-<timestamp2>/STSWSN-PC_INSTANCES/graph100_8_2.txt` (prima la regola GZip `x-fmt/266`, poi la regola TAR `x-fmt/265`);

- **405 file Plain Text** estratti e identificati singolarmente.

Ne consegue che disabilitando la regola GZip **la catena si ferma al primo passo**: la regola TAR resta attiva ma non viene mai raggiunta, e i `.tar.gz` non vengono estratti affatto.

Il test ha mostrato anche il **fattore di moltiplicazione**: 16 file dichiarati dall'API hanno prodotto **465 oggetti** nell'AIP ( $29\times$ ).

#### 10.4 Decisione adottata: configurazione differenziata a due lotti

Poiché nessuna regola può distinguere i due casi, la scelta è **differenziare per lotto** anziché per formato:

| Fase                                   | Regola GZip x-fmt/266 | Dataset                                                                                                 |
|----------------------------------------|-----------------------|---------------------------------------------------------------------------------------------------------|
| <b>Lotto generale</b>                  | <b>disabilitata</b>   | 665 dataset: nessun blob inutile sugli ~11 500 <code>.rds</code> e <code>.fastq.gz</code>               |
| <b>Lotto dedicato agli archivi tar</b> | <b>riattivata</b>     | 7 dataset: T99WYI, EIMQRQ, 3QA23K, IHTWC0, WHRHCT, BFQ87D, WCZXRK — estrazione completa in due passaggi |

Motivazione da verbale: *l'estrazione dei file GZip a file singolo produce oggetti non utilizzabili e non identificabili, senza guadagno di conservazione, mentre l'oggetto autentico da preservare è il file compresso stesso. Poiché Siegfried non può distinguere un file singolo compresso da un archivio tar compresso (stesso PUID x-fmt/266), la regola di estrazione viene disabilitata per la lavorazione generale e riattivata per il solo lotto dei dataset che contengono veri archivi tar, verificati uno per uno.*

Questa soluzione non lascia nulla sul tavolo: i `.rds` restano intatti e i `.tar.gz` vengono comunque estratti.

**Vincolo di sequenzialità.** La regola FPR è globale: quando è riattivata vale per **qualunque** transfer in corso. Il lotto dedicato va quindi lavorato da solo, accertandosi che nessun altro lotto sia in lavorazione, e la regola va ridisabilitata subito dopo.

**Da mettere a verbale:** la configurazione FPR **non è stata uniforme** su tutto il corpus, ma differenziata consapevolmente per categoria di dataset. È una scelta legittima e documentabile, purché appunto documentata: senza questa nota, in sede di audit apparirebbe come un'incoerenza.

#### 10.5 Applicazione e verifica

**Attenzione:** nel FPR “format version” e “rule” sono due cose diverse, e la schermata si somiglia. Entrambe mostrano Description / Enabled / Actions, ma:

- `/fpr/format/gzip/...` è la **definizione del formato** (format version): serve a riconoscere il PUID. Disabilitarla fa diventare Unknown **tutti** i file di quel formato — nel nostro corpus circa 11 500 `.rds` e `.fastq.gz` perderebbero il PUID.
- `/fpr/fprule/extract/` è l'elenco delle **regole di estrazione**: è qui che si disabilita l'unpacking, senza toccare l'identificazione.

L'errore è stato commesso durante il pilota: disabilitando la format version l'estrazione effettivamente cessava, ma il `.rds` risultava Unknown nel METS.

**Configurazione corretta:**

| Voce                                   | Percorso                          | Stato                              |
|----------------------------------------|-----------------------------------|------------------------------------|
| Format version <b>GZip</b> (x-fmt/266) | <code>/fpr/format/gzip/</code>    | <b>Enabled</b> — conserva il PUID  |
| <b>Regola di estrazione</b> GZip       | <code>/fpr/fprule/extract/</code> | <b>Disabled</b> — niente unpacking |
| Regole di estrazione ZIP, 7z, TAR, RAR | <code>/fpr/fprule/extract/</code> | Enabled                            |

**Verifica eseguita** (dataset HADWPV, contiene un .rds), METS dell'AIP:

- nessun evento unpacking;
- `piste_background_buffer_5_10.rds` -> **GZip x-fmt/266** (non più Unknown);
- oggetti scesi da 11 a 10.

Comandi di verifica:

```
rm -f /tmp/stato_test_rds.json
python3 archivematica_ingest.py --source "$TS_PATH/TEST_RDS" --auto-approve \
  --state-file /tmp/stato_test_rds.json
# poi, sull'AIP prodotto, elencare formato e PUID di ogni oggetto dal METS
```

**Altre note operative:**

1. **Disabilitare, non eliminare:** la voce resta tracciata e la scelta è reversibile.
2. La modifica vale solo per i transfer **avviati dopo:** quelli in corso usano le regole lette in partenza.
3. Per il **lotto dedicato** ai .tgz va riabilitata la **sola regola di estrazione**, non la format version (che resta sempre abilitata). Al termine va ridisabilitata.
4. Gli AIP di prova prodotti prima della modifica vanno rifatti insieme al resto del corpus.

## 11. Export dei metadati per versione: limite noto dell'istanza

Durante i test è emerso che l'endpoint `/api/datasets/export` di `dataverse.unimi.it` **rifiuta il parametro version:** per ogni versione non corrente risponde 400 Bad Request.

```
HTTP 400 ... /api/datasets/export?exporter=dataverse_json&persistentId=...&version=1.0
[ATTENZIONE] Export dataverse_json non riuscito
```

Su un dataset con 4 versioni, gli export riescono solo per l'ultima (v1.3) e falliscono per v1.0, v1.1, v1.2. È la ragione tecnica per cui `schema.json` è presente solo nella cartella dell'ultima versione (cfr. manuale).

**Conseguenza operativa da valutare prima del lotto completo:** lo script esegue **3 tentativi con retry** per ogni export fallito, cioè 6 chiamate inutili per versione (due exporter). Sulle 1 226 versioni dello scope sono diverse migliaia di richieste sprecate, che allungano i tempi e caricano inutilmente il server.

Poiché un 400 è un errore **definitivo** e non transitorio, non andrebbe ritentato. La correzione è circoscritta a `scarica_dataverse.py` e conviene applicarla prima della lavorazione estesa.

## 12. Piano dei lotti e calibrazione

Lo scope si suddivide con `prepara_lotti.py`, che legge il report di Fase 0 e bilancia i lotti su **numero di file e volume**, non sul conteggio dei DOI: il corpus è estremamente disomogeneo (da 1 file a quasi 15 000 per dataset) e lotti "da N DOI" avrebbero durate imprevedibili.

```
python3 prepara_lotti.py --max-file 2000 --max-gb 20 --max-doi 200 --scrivi
```

Con queste soglie lo scope dei 672 DOI si ripartisce in **27 lotti** (67 730 file, 62,95 GB). La struttura riflette due popolazioni distinte:

- **lotti 01-20:** dominati dal numero di file, quasi tutti un solo DOI (il maggiore ha 14 888 file, il 22% dei file dell'intero corpus);
- **lotti 21-27:** dominati dal numero di pacchetti (511 DOI per ~2 100 file), dove il costo è quasi tutto overhead per transfer.

**Un solo file di stato per l'intera ri-acquisizione** (`stato_riacquisizione.json`): è ciò che impedisce doppi ingest se un DOI comparisse in due lotti o se un lotto venisse rilanciato.

### 12.1 Dati di calibrazione misurati

La calibrazione è stata fatta su **due lotti dal profilo opposto**, per isolare le due componenti di costo: l'overhead fisso per pacchetto e il lavoro per file.

**LOTTO\_27 — 111 DOI, 118 file, 2 GB** (quasi solo overhead):

| Indicatore                 | Valore                                            |
|----------------------------|---------------------------------------------------|
| Pacchetti completati       | 110 su 111                                        |
| Tempo totale ingest        | 75,5 min                                          |
| <b>Media per pacchetto</b> | <b>41,6 s</b> (mediana 40 s, min 25 s, max 251 s) |

**LOTTO\_14 — 1 DOI, 1 036 file, 0,03 GB** (un solo pacchetto, molti file):

| Fase     | Tempo                                  | Coefficiente       |
|----------|----------------------------------------|--------------------|
| Download | 3 min 19 s                             | <b>0,19 s/file</b> |
| Ingest   | 4 min 30 s (di cui 41,6 s di overhead) | <b>0,22 s/file</b> |

Il tempo per pacchetto è dominato dall'attesa di approvazione (10 s) e dal polling (intervalli di 15 s), quindi è **indipendente dalla dimensione del pacchetto**. Nel download l'83% del tempo è attesa di rete (`user+sys` = 32 s su 199): il collo di bottiglia è la latenza per richiesta, non la macchina.

### 12.2 Stima dell'intera ri-acquisizione

| Componente                  | Calcolo              | Tempo          |
|-----------------------------|----------------------|----------------|
| Download                    | 67 730 file x 0,19 s | ~3,6 h         |
| Ingest — overhead pacchetti | 671 x 41,6 s         | ~7,8 h         |
| Ingest — lavoro sui file    | 67 730 x 0,22 s      | ~4,1 h         |
| <b>Totale processing</b>    |                      | <b>~15,5 h</b> |

A cui si aggiunge il tempo dei Gate fra un lotto e l'altro, che dipende dall'operatore e non dalla macchina.

**Margine di incertezza da dichiarare:** i coefficienti sono misurati su file minuscoli (il LOTTO\_14 pesa 0,03 GB), quindi catturano la latenza ma non la banda. Sui 63 GB reali — con casi come un `.dta` da 235 MB o un `.tar` da 2,4 GB — il tempo di trasferimento effettivo si somma. Stima realistica: **18-20 ore**, distribuite su più sessioni.

Due conseguenze per la pianificazione:

- **l'overhead per pacchetto domina** (7,8 h su 15,5). È il costo fisso dei 671 transfer, indipendente dalla loro dimensione: alzare le soglie per lotto non allunga i tempi totali, riduce solo il numero di cicli manuali. L'unica leva per ridurlo sarebbe abbassare gli intervalli di polling in `archivematica_ingest.py`, valutando però il carico sulla Dashboard;
- il **lotto oversize da 14 888 file** si stima in circa **1,7 h** complessive (47 min di download, 55 min di ingest): pesante ma gestibile in una sessione.

## 13. Criteri di GO / NO-GO per il lotto completo

Si procede al lotto dei 702 dataset **solo se**:

- entrambi i Gate del pilota sono superati senza eccezioni;
- in particolare il Pilota B dimostra che i file **ristretti e ingeriti** vengono scaricati come originali (nessun [FALLBACK], conteggio file corretto);

- è stata presa una decisione **strutturale** sulla collocazione di `TRANSFER_SOURCE`: 63 GB in 67 730 file dentro una cartella sincronizzata con Dropbox riproporrebbero i lock transitori su larga scala. La sospensione manuale della sincronizzazione non è sufficiente per una lavorazione lunga, perché Dropbox può riprendere dopo un riavvio o un aggiornamento del client;
- lo spazio disponibile copre 63 GB di download più lavorazione e AIP;
- è stato definito il **dimensionamento dei lotti** (per esempio 50–100 DOI per volta) e il punto di ripresa in caso di interruzione. I lotti si organizzano in **sottocartelle della Transfer Source Location** (`LOTTO_01`, `LOTTO_02`...), da indicare con `--source`: è verificato che Archivematica le risolva correttamente. Omettere `--source` farebbe usare la radice della location, con il rischio di rilavorare tutti i pacchetti presenti;
- la **processing configuration** è quella corretta (prerequisito 4.7): un errore qui obbligherebbe a rifare tutti gli AIP del lotto;
- la **politica di trattamento degli archivi** è stata decisa, applicata e verificata con il test del `.rds` (sezione 10.5): regola di estrazione GZip disabilitata, format version GZip **abilitata**. Modificarla a metà lavorazione produrrebbe un corpus disomogeneo, con alcuni AIP contenenti blob estratti e altri no, o con PUID mancanti;
- il **censimento degli archivi** (`censisci_archivi.py`) è completo, senza DOI rimasti non analizzati: i dataset che contengono archivi hanno un carico reale molto superiore a quello dichiarato dall'API e vanno collocati nei lotti di conseguenza;
- i DOI del lotto sono stati **riverificati poco prima di lavorarlo** (sezione 8.2): lo scope non è stabile, un dataset è scomparso nell'arco di due giorni durante la lavorazione stessa;
- i **7 dataset con archivi tar** sono stati estratti dal piano generale e raccolti in un **lotto dedicato** da lavorare separatamente con la regola GZip riattivata (sezione 10.4).

Nota a favore: la ri-acquisizione è ripartibile in sicurezza. Lo skip si basa su dimensione e checksum, quindi rilanciare non lascia file monchi; un download interrotto viene ri-scaricato al passaggio successivo.

## 14. Registrazione dell'esito

Al termine del pilota annotare, per ciascun dataset: data di esecuzione, esito dei due Gate, UUID dell'AIP prodotto, anomalie riscontrate e correzioni applicate. Questo verbale è la base documentale della ricostruzione del corpus e va conservato insieme alla documentazione del progetto.

### 14.1 Esito del pilota del 22 luglio 2026

**Gate 1 superato** su entrambi i dataset: 36 file scaricati (10 + 26), di cui 31 come originali (`format=original`) e 5 non ingeriti; nessun `[FALLBACK]`, nessun `.tab` su disco, nessun errore o riscarico. Le 4 versioni di PKZ7FJ e le 3 di DP08SC complete. Le 36 `dcats:distribution` coerenti: 31 con `?format=original`, 5 senza (file non ingeriti).

**Gate 2 superato:** formati identificati da Siegfried 1.11.2 (25 Microsoft Excel su DP08SC, più PDF, CSV, JSON, Plain Text), nessun Unknown, nessun Tab-Separated Values. Su PKZ7FJ 2 eventi di `normalization` con 2 derivate PDF/A validate. I 25 nomi con spazi risultano sanificati sul filesystem e documentati in `originalName` con relativi eventi `filename change`.

#### Anomalie riscontrate e risolte durante il pilota:

1. *Ingest fallito con i pacchetti in sottocartella* (`Filepath ... does not exist`): bug di `archivematica_ingest.py`, che ricostruiva il percorso dal solo nome della cartella perdendo la sottocartella. Corretto passando il path assoluto del pacchetto; verificato con un transfer completato da sottocartella.
2. *Tutti i formati Unknown al primo ingest*: identificazione dei formati disattivata nella processing configuration (vedi prerequisito 4.7). Corretta e ingest ripetuto.
3. *Permessi in scrittura sulla Transfer Source*: il mount `drvfs` usa `uid=333;gid=333;umask=022`, quindi al gruppo manca il bit `w`. Risolto con `chmod g+ws` sulla cartella; per il lotto va valutata una soluzione stabile (`umask=002` in `/etc/wsl.conf` o riposizionamento della location).

### 14.3 Esito del LOTTO\_14 (calibrazione del costo per file)

1 DOI, 4 versioni, **1 036 file** (0,03 GB), nessun archivio compresso.

- Download: **1 036 file su 1 036**, zero errori, nessun [FALLBACK], nessun .tab su disco — 3 min 19 s.
- Ingest: completato senza errori — 4 min 30 s. AIP 23bbfdf9-a35e-4ed4-9b22-c8bcad142635.

È il secondo lotto reale registrato in `stato_riacquisizione.json` e ha fornito il coefficiente di costo per file (sezione 12.1), completando la stima complessiva della ri-acquisizione.

Nota strutturale emersa: le 4 versioni contengono 259 file ciascuna, cioè lo stesso contenuto scaricato quattro volte. È il comportamento atteso della struttura per versione (`objects/<versione>/objects/`) e spiega perché il conteggio dei file del piano è più alto di quanto i dataset sembrino contenere.

### 14.2 Esito della calibrazione sul primo lotto reale (LOTTO\_27)

111 DOI leggeri (118 file, 2 GB): **110 ingeriti, 1 fallito**, 75,5 minuti, media 41,6 s per pacchetto (vedi 12.1).

Il caso fallito — un dataset composto da un unico archivio compresso da 610 MB — ha fatto emergere tre problemi a catena, tutti documentati nella sezione 9: la domanda *Extract packages?* non coperta dalla configurazione (9.1), il disallineamento di MCPClient dopo il riavvio di MCPServer (9.2) e il riaggancio di un transfer annullato rimasto nel file di stato (9.3).

**Lezione per il lotto completo:** un solo caso su 111 è circa lo 0,9%, che sui 672 pacchetti significherebbe una sessantina di transfer bloccati. Il censimento preventivo con `censisci_archivi.py` ha poi individuato **39 dataset con archivi compressi** (12 043 archivi, 11,88 GB), portando alla revisione della politica di estrazione documentata nella sezione 10.

Da questo caso è emerso anche che il piano dei lotti **sottostima sistematicamente** i dataset contenenti archivi: WPOXS5 risultava «1 file, 0,58 GB» e ha prodotto **2 238 elementi** nell'AIP (1 859 eventi di unpacking), perché conteneva un archivio NMR con una gerarchia profonda 10 livelli. I lotti che contengono dataset con archivi vanno quindi considerati più pesanti di quanto il conteggio dei file suggerisca.

---

## 15. Fase 2 — Ambiente dedicato e migrazione degli AIP in produzione

### 15.1 Impostazione

La ri-acquisizione completa viene eseguita su una **workstation dedicata**, dove Archivematica gira in locale (`localhost`) con risorse sufficienti. Al termine, verificata la qualità del risultato, gli AIP prodotti vengono **migrati sull'istanza di produzione**.

Questa impostazione ha due conseguenze operative:

- l'istanza sulla workstation va **svuotata completamente** prima di iniziare, per avere un ambiente pulito e dedicato: niente AIP sperimentali, niente job zombie, niente record orfani dalle lavorazioni precedenti;
- il percorso di migrazione va **verificato in anticipo** su un solo AIP, non scoperto dopo la produzione di centinaia di pacchetti.

### 15.2 Cosa si perde svuotando l'istanza

Lo svuotamento cancella i database MySQL (Dashboard e Storage Service) e gli indici Elasticsearch. Con essi spariscono anche configurazioni che sono costate lavoro e che **non sono nel repository**:

| Elemento                                                                                          | Dove vive                | Come si recupera                                                              |
|---------------------------------------------------------------------------------------------------|--------------------------|-------------------------------------------------------------------------------|
| <b>Configurazione FPR</b> (regola di estrazione GZip disabilitata, format version GZip abilitata) | database Storage Service | <b>da rifare a mano</b> e riverificare col test <code>.rds</code> (sez. 10.5) |
| Processing configuration <code>dataverse_001</code>                                               | database Dashboard       | l'XML è già in <code>~/arkive/config/</code> : si reimporta                   |
| UUID della Transfer Source Location                                                               | database Storage Service | <b>cambia:</b> aggiornare il <code>.env</code>                                |
| UUID della pipeline                                                                               | database Dashboard       | <b>cambia:</b> rilevante per la migrazione (sez. 15.5)                        |
| API key Dashboard e Storage Service                                                               | database                 | <b>cambiano:</b> aggiornare il <code>.env</code>                              |

**Prima di svuotare**, annotare: location definite nello Storage Service (nome, purpose, path, UUID), impostazioni FPR modificate, e una copia del `.env` corrente.

### 15.3 Ricollocare la Transfer Source fuori da Dropbox

Poiché lo svuotamento impone comunque di **ricreare le location** nello Storage Service, è il momento giusto — e a costo nullo — per spostare `TRANSFER_SOURCE` fuori dalla cartella sincronizzata con Dropbox. Farlo dopo significherebbe rifare la configurazione.

La collocazione naturale è accanto all'AIPsStore, che è **già fuori da Dropbox**:

```
/mnt/e/ARKIVE/AIPsStore/      <- esistente
/mnt/e/ARKIVE/TRANSFER_SOURCE/ <- nuova collocazione
```

Vantaggi rispetto alla sospensione manuale della sincronizzazione:

- nessun rischio che Dropbox riprenda da solo dopo un riavvio o un aggiornamento del client, nel mezzo di una lavorazione di ore;
- nessun caricamento di 63 GB alla riattivazione;
- meno attrito sui permessi `drvfs` a ogni lotto (25 cicli).

Se per ragioni proprie si preferisce restare dentro Dropbox, usare la **Selective Sync** (esclusione persistente della cartella) e non la sospensione manuale, che è uno stato temporaneo.

Resta comunque necessaria l'opzione di mount `metadata` (prerequisito 4.2).

### 15.4 Procedura di ripartenza pulita

1. **Annotare** la configurazione corrente (sez. 15.2) e copiare il `.env`.
2. **Svuotare** l'istanza Archivematica della workstation.
3. **Ricreare le location** nello Storage Service, con `TRANSFER_SOURCE` nella nuova collocazione fuori da Dropbox.
4. **Reimportare** la processing configuration `dataverse_001` e verificarne le scelte (prerequisito 4.7).
5. **Riapplicare il FPR**: regola di estrazione GZip disabilitata, format version GZip abilitata — e **riverificare col test `.rds`** (sez. 10.5), perché è la configurazione più facile da sbagliare.
6. **Aggiornare il `.env`** con i nuovi UUID e le nuove API key.
7. **Test di migrazione su un solo AIP** (sez. 15.5) — prima dei lotti, non dopo.
8. Avviare la lavorazione dei lotti.

### 15.5 Test di migrazione: un AIP prima di 671

La migrazione si appoggia a `bulk_register_aips.py`, che è esattamente lo strumento per questo scenario. Il meccanismo funziona perché il **path a quadranti è deterministico dall'UUID**: due istanze Archivematica diverse calcolano lo stesso percorso per lo stesso AIP, quindi i pacchetti possono essere copiati fra istanze e

registrati senza spostamenti fisici (se `origin_path` e `current_path` coincidono, la Storage Service registra il record e basta).

Il percorso di migrazione è quindi:

1. copiare i file dell'AIP nell'AIPsStore di produzione, rispettando la struttura a quadranti;
2. registrarli con `bulk_register_aips.py` (variabili `SS_URL`, `SS_USER`, `SS_API_KEY`, `TARGET_LOCATION_UUID`);
3. rigenerare l'indice Elasticsearch sul Dashboard di produzione (`rebuild_aip_index_from_storage_service`), altrimenti gli AIP risultano registrati ma **invisibili** nella scheda *Archival Storage*;
4. verificare che l'AIP sia consultabile e che il **pointer file** sia valido.

**Perché farlo subito e su un solo pacchetto:** gli AIP prodotti sulla workstation portano con sé l'`origin_pipeline` di quell'istanza, non della produzione, e il pointer file viene generato in fase di storage. Se la produzione rifiutasse quei record, o se il pointer risultasse malformato, il problema si manifesterebbe **identico su tutti i 671 pacchetti**. Scoprirlo dopo venti ore di lavorazione comporterebbe rifare tutto.

Si usa uno degli AIP pilota già disponibili: è materiale sacrificabile e sufficiente a validare l'intero percorso.

## 15.6 Criterio di chiusura della Fase 2

Si considera la migrazione praticabile quando, sull'AIP di prova:

- il record risulta registrato nella Storage Service di produzione con `status=UPLOADED`;
- l'AIP compare nella scheda *Archival Storage* del Dashboard dopo la rigenerazione dell'indice;
- il pointer file è presente e valido;
- il contenuto è verificabile (fixity, METS leggibile).